

Safety Alignment Evaluation of Subtasks in LLM Agents

大模型代理中子任务的安全对齐评估

Zhichao Liu

Harbin Institute of Technology

August 21, 2025



Table of Contents

Research Background

Dataset Construction Method

Dataset Construction

Model Evaluation

Summary



Problem Premise

- 模型做代理任务时的越狱后果更严重
 - 正常对话任务中，越狱场景更少、破坏力更小
 - 代理场景下会与现实世界交互，破坏力更强
- 代理场景与对话场景的越狱形式不同
 - 对话场景：单次语言交互，要求模型理解语义层面的安全概念
 - 代理场景：要求模型对有害目标有贡献即可，可能只是危险意图的子任务



Problem Premise (cont.)

- 代理场景的对齐比对话对齐更困难
 - 对模型遵守指令完成任务的要求比对话更强
 - 模型会分配更多注意力在任务本身
 - 与对齐要求模型适当拒绝用户产生了冲突



Related Work - Jailbreak Evaluation

- **Latent Jailbreak**¹: 通过在不同位置嵌入恶意指令进行攻击
- **AdvBench**²: 自动化搜索对抗后缀，攻击在多模型间可迁移
- **JailbreakHub**³: 收集和分析 1,405 个社交媒体上的越狱提示
- **Do-Not-Answer**⁴: 关注模型拒绝高风险任务的能力
- **ToxicChat**⁵: 利用真实对话数据揭示有害内容检测挑战

¹Qiu et al., "Latent Jailbreak." arXiv (2023).

²Zou et al., "AdvBench." arXiv (2023).

³Shen et al., "JailbreakHub." arXiv (2024).

⁴Wang et al., "Do-Not-Answer." arXiv (2023).

⁵Lin et al., "ToxicChat." arXiv (2023).



Related Work - Jailbreak Evaluation (cont.)

关键问题

这些数据多依赖简单注释或直接的恶意输入，危险意图往往过于显性，难以模拟真实应用场景



Related Work - Agent Workflows

- **AutoGen & AutoAgents**: 提供多角色对话编程，支持动态调度与灵活角色配置
- **AUTOACT**: 引入元代理 (Meta-Agent)，强化任务分解与工具调用
- **UFO**: 面向 Windows 的多应用协作与 UI 自动化
- **AutoDev**: 结合代理调度与容器环境，支持大规模协同开发
- **Langgraph**: 利用图结构实现任务管理与上下文控制，提升可扩展性



- 提出可扩展且稳定的样本生成方法
 - 能够提供具有挑战性的 Agent 对齐测试样本
- 收集涵盖 workflows 场景的安全对齐基准
 - 覆盖 Agent 最典型的几个任务类型
 - 整合多个来源的恶意意图数据源
- 提出新的对齐样本评估指标
 - 在 PAIR、PAP 等方法上进行了评估



Traditional Jailbreak Evaluation Paradigm

- 将恶意意图形式化为二元组: $I = (G, M)$
 - G : 真实恶意目标 (如生成有害输出)
 - M : 对 G 施加的伪装/变换集合 (如改写、混淆)
- 通过越狱方法 Φ 生成对抗输入: $I' = \Phi(I)$
- 目标模型: $f_{\theta}(x)$; 对抗输入的响应: $r = f_{\theta}(I')$
- 传统评估目标: 最大化模型产生不安全响应的概率

$$\arg \max_{I'} \Pr (f_{\theta}(I') \in \mathcal{R}_{\text{unsafe}})$$



Traditional Jailbreak Evaluation Paradigm (cont.)




Figure 1: 当前越狱基线评估范式

问题

仅测试在抽象/可控环境下的脆弱性，难以反映真实 workflow 稳健性



Workflow Safety Evaluation Paradigm

- 将真实任务拆解为多阶段工作流
- 在第 t 步, 给定历史 $H_t = \{o_1, \dots, o_{t-1}\}$ 与当前子任务 T_t
- 输出: $o_t = f_\theta(H_t, T_t)$
- 评估目标转为最大化安全输出概率:

$$\max \Pr(o_t \in \mathcal{R}_{\text{safe}} \mid H_t, T_t)$$

- 差异: 不再强调伪装 Φ 的有效性, 而是衡量模型在逐步诱导与任务上下文暴露下的对抗抵抗能力与风险传播



Workflow Safety Evaluation Paradigm (cont.)




Figure 2: 本文提出的评估范式

Context Difference and Task Alignment

- 现有上下文方法（如 PAIR）常弱化或偏离原始危险目标
- 导致“看似安全”的迁移
- 本文方法：保持危险意图不变、仅约束表达形式



Context Difference and Task Alignment (cont.)




Figure 3: 三种输入方式对比：原始/PAIR/本文

Dangerous Workflow Simulation System - Phase A

- 阶段 A：危险任务生成
 - 从初始危险意图出发
 - 使用攻击代理模拟若干轮工作历史
 - 锚定当前轮次的子任务描述
 - 目标：生成贴近真实流程的“在途”任务，而非一次性目标描述



Dangerous Workflow Simulation System - Phase B

- 阶段 B：任务描述优化
 - 使用对齐模型标注并识别”触发直接拒绝”的禁词集合
 - 在保持原始危险目标不变的前提下
 - 由攻击代理对任务描述进行迭代改写
 - 降低显性禁词、提高潜在危害聚焦度



Dangerous Workflow Simulation System




Figure 4: 危险子任务提示的仿真系统

Sample Scalability and Stability

- 样本生成借鉴 PAIR 与 StrongREJECT 的思路
 - 引入执行历史仿真
 - 确保子任务”具体、可执行、可控”
- 产出两个集合
 - JailFlowEval (>3000 条样本)
 - JailFlowEval-hard (高质量子集 700 条)
- 优势：与传统”小规模人工标注”基座相比，本数据集在规模与 workflow 贴近性上更具挑战性



Data Source Collection

Dataset	Scale	Manual annotation	Automatic annotation
StrongREJECT	288	✓	
AdvBench	509	✓	✓
do-not-answer	938		✓
toxic-chat	701	✓	
HarmBench	191	✓	
JailbreakBench	200	✓	

Table 1: 六个数据源与规模（总规模 >3000，另含高质量子集 700）



- 对问题进行编码与聚类，获得 11 个主题：
 1. 恶意操纵与伤害
 2. 不敬与争议/有害观点
 3. 角色扮演与创作
 4. 非法活动教程
 5. 危险/自伤指令
 6. 有害内容创作
 7. 敏感/争议信息



Topic Extraction (cont.)

- 8. 黑客/网络犯罪
- 9. 明确性内容
- 10. 恶意工具与行动
- 11. 逃避责任与犯罪行为






Figure 5: 基于意图主题聚类得到的 11 个主题分布

Subtask Scope

- 统计近期 **Agent** 系统常见 10 类子任务
- 本基准选择最常用的三大组件进入 workflow:
 - 任务规划 (Planning)
 - 子任务执行 (Execution)
 - 任务改进 (Improvement) —— 细分为纠错与效果优化



Agent Framework Support

Agent framework	Planning	Analysis	RAG	Execution	Code	Tool	Reflection	Memory
Camel	✓			✓		✓	✓	
MetaGPT	✓	✓		✓	✓	✓	✓	
HuggingGPT	✓			✓			✓	
Autogen	✓		✓	✓	✓	✓	✓	
ChatDev	✓			✓			✓	✓



Agent Framework Support (cont.)

Agent framework	Planning	Analysis	RAG	Execution	Code	Tool	Reflection	Memory
Langgraph	✓			✓			✓	
UFO	✓		✓	✓			✓	✓
AutoDev	✓			✓	✓	✓	✓	
AUTOACT	✓			✓			✓	
AutoAgents	✓		✓	✓	✓	✓	✓	✓

Table 2: 不同 Agent 框架在子任务上的支持情况



Model Alignment Metrics - PAIR Score

- **PAIR Score** (任务完成度 × 危害性)
- 定义: $R(S) = f(C(S), V(S))$
 - $C(S)$: 对当前子任务的清晰度/特异性/正确性
 - $V(S)$: 响应跨越伦理/法律/安全边界的程度
- 特点:
 - 面向具体子任务的功能性与安全性评价
 - 更契合工作流衡量
 - 与 StrongReject 相比, 不强调“说服力”维度



Model Alignment Metrics - PAIR Score (cont.)

备注

适用于判断“是否真正完成了危险子任务”，而非仅生成“有害片段”



Data Quality Metrics - Mutual Information

- 设定

- 数据集中提示集 $X = \{x_i\}_{i=1}^N$ ，响应集 $Y = \{y_j\}_{j=1}^M$
- 假设 $p(x_i) = 1/N$
- 以相似度 s_{ij} 计算条件分布 (Softmax):

$$p(y_j | x_i) = \frac{\exp(s_{ij})}{\sum_{k=1}^M \exp(s_{ik})}$$



Data Quality Metrics - Mutual Information (cont.)

- 互信息定义

$$I(X; Y) = \sum_{i=1}^N \sum_{j=1}^M \frac{1}{N} p(y_j | x_i) \log_2 \left(\frac{p(y_j | x_i)}{p(y_j)} \right)$$

- 成对贡献

$$I(x_i; y_i) = \frac{1}{N} p(y_i | x_i) \log_2 \left(\frac{p(y_i | x_i)}{p(y_i)} \right)$$

解释

用于捕捉成功响应在不同提示之间的可区分性/专一性



Dataset Direct Metrics - Keyword Density

- 对每个提示 p_i , 抽取得到关键词集合 $K(p_i) = \{k_1, \dots, k_{m_i}\}$, 长度 L_i
- 密度: $d_i = \frac{m_i}{L_i}$
- 数据集平均: $d_{\text{avg}} = \frac{1}{N} \sum_{i=1}^N \frac{m_i}{L_i}$



Dataset Direct Metrics - Keyword Relevance

- 关键词嵌入 $e(k) \in \mathbb{R}^d$; 任意对 (k_j, k_ℓ) 的相似度

$$S_{j\ell} = \frac{e(k_j) \cdot e(k_\ell)}{\|e(k_j)\| \|e(k_\ell)\|}$$

- 单条提示的平均相关性:

$$r_i = \frac{2}{m_i(m_i - 1)} \sum_{1 \leq j < \ell \leq m_i} S_{j\ell}$$

- 数据集平均: $r_{\text{avg}} = \frac{1}{N} \sum_{i=1}^N r_i$



Dataset Direct Metrics - Keyword Relevance (cont.)

用途

在不依赖模型的情况下，衡量提示的语义集中度与主题一致性



Evaluation Results - Method Comparison

- 设置：在 JailFlowEval-hard 上，收集本文/PAIR/PAP misrepresentation 三种方法生成的样本
- 与 gpt4o-mini 评测得到交集 370 条进行比较

Method	ours	pair	pap misrepresentation
Score	0.7283	0.6449	0.4188
Weighted density	0.0699	0.0951	0.0614
Weighted relatedness	0.4876	0.4369	0.2799

Table 3: 不同指标下的分数



Evaluation Results - Method Comparison (cont.)

结论

本文循环式场景生成在越狱能力与语义集中度两方面均占优；PAIR 次之；PAP 明显偏弱



Model Comparison - Scope

- 闭源模型：
 - gpt-4o、 gpt-4o-mini
 - claude-3.5-sonnet、 claude-3.5-haiku-20241022
 - gemini-2.0-flash-001
- 开源模型：
 - llama-3.1-70b-instruct、 llama-3.1-8b-instruct
 - qwen-2.5-72b-instruct、 qwen-2.5-7b-instruct
 - deepseek-chat



Model Comparison - Results




Figure 6: 主要结果 (Direct Score 越低越好; MI/加权 MI 越高越好)



Model Comparison - Key Findings

- 开源模型整体安全性弱于闭源，且开源内部差异相对较小
- 能力更强的开源模型未必更安全：DeepSeek V3（deepseek-chat）表现出最差安全性
- 闭源中：
 - Claude 系列对齐稳健性最强，几乎在多任务/多格式均能稳定拒绝
 - GPT-4o 与 GPT-4o-mini 对齐能力较弱，其中 Mini 更易受危险指令影响
 - Gemini 2.0 Flash 相对更稳健



Method Effectiveness and Quality Visualization



Figure 7: 三列对比: Direct Score↑、密度 ↓、相关性 ↑

Method Effectiveness and Quality Visualization (cont.)

- 可视化要点：
 - 在有效越狱样本范围内，本文方法在关键词密度更低（表达更凝练）
 - 关键词相关性更高（主题更聚焦）
 - 第二阶段引入任务主题约束后，循环不会偏离原任务内容
 - 保持”危险目标不变”同时使表达更隐蔽



Summary - Contributions

- 提出 JailFlowEval
 - 在真实工作流中、围绕规划—执行—改进的危险子任务
 - 评估模型对齐能力
 - 提供 >3000 / 700 高质量样本
- 提出评估指标体系
 - PAIR Score
 - 互信息
 - 关键词密度/相关性



Summary - Findings

- 开源模型在工作流场景的对齐明显不足
- 闭源中 Claude 系列显著更稳健
- 构造方法方面：
 - 本文循环式场景生成在“越狱成功率 + 语义集中度”上均优于 PAIR/PAP



Summary - Practical Guidelines

实践指引

在 Agent 工作流落地前，需要以工作历史 + 子任务为单位做安全回归测试，而非只在对话场景做一次性越狱评测



Discussion Points

- 实验只是比较浅地套了 **agent** 的概念，本质上没有触及 agent”与现实世界交互”的核心点
- 两种思路的权衡：
 - 从 jailbreaking 入手往 agent 的形式上靠（本文做法）
 - 从 agent 任务入手增加 jailbreaking 因素
- 模型对于 **agent** 系统中的冲突：
 - agent 任务能力要求 follow 指令
 - 安全对齐要求审核后适当拒绝



Discussion Points (cont.)

- 目前实验的局限性：
 - 初稿实验有些过时
 - 已经出现了一些 agent 对齐研究



Q&A

